

08

Association Rule Discovery: Apriori Algorithm



Association Rule Mining

- Given a set of transactions, find rules that will predict the occurrence of an item based on the occurrences of other items in the transaction
- Example of Association Rules: {Diaper} → {Beer}, {Milk, Bread} → {Eggs, Coke}
- Implication means co-occurrence, not causality!

Market-Basket transactions

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

A binary 0/1 representation of market basket data

TID	Bread	Milk	Diapers	Beer	Eggs	Coke
1	1	1	0	0	0	0
2	1	0	1	1	1	0
3	0	1	1	1	0	1
4	1	1	1	1	0	0
5	1	1	1	0	0	1

การค้นหากฎความสัมพันธ์ (Association Rules Mining)



การวิเคราะห์ความสัมพันธ์ของข้อมูลระหว่างรายการ โดยจะทำการค้นหา และดึงรูปแบบของข้อมูลระหว่างรายการต่างๆ ที่ถูกจัดเก็บไว้ในฐานข้อมูล และสร้างให้อยู่ในรูปแบบของกฎความสัมพันธ์ เช่น ถ้านำรายการขายแต่ละรายการของ ห้างสรรพสินค้ามาวิเคราะห์ อาจจะพบความสัมพันธ์ว่าถ้าลูกค้าซื้อผ้าอ้อมแล้วจะซื้อเบียร์ด้วย

Application

Frequently Bought Together



+



+



Total price: ₹274.00

Add all three to Cart

- ☒ **This item:** One Indian Girl by Chetan Bhagat Paperback ₹70.00
- ☒ Half Girlfriend by Chetan Bhagat Paperback ₹88.00
- ☒ Revolution Twenty 20: Love. Corruption. Ambition by Chetan Bhagat Paperback ₹116.00

Customers Who Bought This Item Also Bought


Page 1 of 17



Half Girlfriend
› Chetan Bhagat
★★★★☆ 5,628
Paperback
₹88.00 Prime




Revolution Twenty 20:
Love. Corruption. Ambition
› Chetan Bhagat
★★★★☆ 697
Paperback
₹116.00 Prime



The 3 Mistakes of My Life
› Chetan Bhagat
★★★★☆ 438
Paperback
₹122.00 Prime



Everyone Has A Story
› Savi Sharma
★★★★☆ 1,690
Paperback
₹75.00 Prime



Life is What You Make it
› Preeti Shenoy
★★★★☆ 2,074
Paperback
₹75.00 Prime



One Night @ The Call
Centre
› Chetan Bhagat
★★★★☆ 398
Paperback
₹109.00 Prime



Definition: Frequent Itemset

- **Itemset**
 - A collection of one or more items
 - Example: {Milk, Bread, Diaper}
 - k-itemset
 - An itemset that contains k items
- **Support count (σ)**
 - Frequency of occurrence of an itemset
 - E.g. $\sigma(\{\text{Milk, Bread, Diaper}\}) = 2$
- **Support**
 - Fraction of transactions that contain an itemset
 - E.g. $s(\{\text{Milk, Bread, Diaper}\}) = 2/5$
- **Frequent Itemset (Large Itemset)**
 - An itemset whose support is greater than or equal to a *minsup* threshold

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Definition: Association Rule

- Association Rule

- An implication expression of the form $X \rightarrow Y$, where X and Y are itemsets

- Example:

$\{\text{Milk, Diaper}\} \rightarrow \{\text{Beer}\}$

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

- Rule Evaluation Metrics

- Support (s)

- Fraction of transactions that contain both X and Y

- Confidence (c)

- Measures how often items in Y appear in transactions that contain X


Example:

$\{\text{Milk, Diaper}\} \Rightarrow \{\text{Beer}\}$

$$s = \frac{\sigma(\text{Milk, Diaper, Beer})}{|T|} = \frac{2}{5} = 0.4$$

$$c = \frac{\sigma(\text{Milk, Diaper, Beer})}{\sigma(\text{Milk, Diaper})} = \frac{2}{3} = 0.67$$

Itemset Generation



Given d items, there are 2^d possible candidate itemsets (C)

Association Rule Mining Task

- Given a set of transactions T , the goal of association rule mining is to find all rules having
 - support $\geq$ *minsup* threshold
 - confidence $\geq$ *minconf* threshold
- Brute-force approach:
 - List all possible association rules
 - Compute the support and confidence for each rule
 - Prune rules that fail the *minsup* and *minconf* thresholds
 - **Computationally prohibitive!**

Computational Complexity

- The number of candidate itemsets at level k is:

$$\binom{d}{k} = \frac{d!}{k! (d - k)!}$$

Binomial Coefficient (สัมประสิทธิ์ทวินาม)
จำนวนวิธีเลือก k สิ่งจาก d สิ่ง โดยไม่สนลำดับและไม่เลือกซ้ำ

where

- d = total number of distinct items in the dataset
- k = size (length) of the itemsets generating

Candidate Itemset Generation: Brute-force method

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

If every subset is considered,

$${}^6C_1 + {}^6C_2 + {}^6C_3 \\ 6 + 15 + 20 = 41$$

$$\binom{d}{k} = \frac{d!}{k!(d-k)!}$$

Items
Item
Beer
Bread
Cola
Diapers
Eggs
Milk




Itemset
Beer, Bread
Beer, Cola
Beer, Diapers
Beer, Eggs
Beer, Milk
Bread, Cola
Bread, Diaper
Bread, Eggs
Bread, Milk
Cola, Diapers
Cola, Eggs
Cola, Milk
Diapers, Eggs
Diapers, Milk
Eggs, Milk



Itemset
{Beer, Bread, Cola}
{Beer, Bread, Diapers}
{Beer, Bread, Eggs}
{Beer, Bread, Milk}
{Beer, Cola, Diapers}
{Beer, Cola, Eggs}
{Beer, Cola, Milk}
{Beer, Diapers, Eggs}
{Beer, Diapers, Milk}
{Beer, Eggs, Milk}
{Bread, Cola, Diapers}
{Bread, Cola, Eggs}
{Bread, Cola, Milk}
{Bread, Diapers, Eggs}
{Bread, Diapers, Milk}
{Bread, Eggs, Milk}
{Cola, Diapers, Eggs}
{Cola, Diapers, Milk}
{Cola, Eggs, Milk}
{Diapers, Eggs, Milk}

Mining Association Rules

- Two-step approach:
 1. Frequent Itemset Generation
 - Generate all itemsets whose support $\geq$ minsup
 2. Rule Generation
 - Generate high confidence rules from each frequent itemset, where each rule is a binary partitioning of a frequent itemset
- Frequent itemset generation is still computationally expensive



Apriori Algorithm

Reducing Number of Candidates

- **Apriori principle:**

If an itemset is frequent, then all of its subsets must also be frequent


- Apriori principle holds due to the following property of the support measure:

$$\forall X, Y : (X \subseteq Y) \Rightarrow s(X) \geq s(Y)$$

- Support of an itemset never exceeds the support of its subsets
- This is known as the **anti-monotone** property of support


A measure f possesses the anti-monotone property if for every itemset X that is a proper subset of itemset Y , i.e. $X \subset Y$, we have $f(Y) \leq f(X)$

Illustrating Apriori Principle



If {c, d, e} is frequent, then all subsets of this itemset are frequent.

Illustrating Apriori Principle



Apriori Algorithm

- F_k : frequent k -itemsets
- C_k : candidate k -itemsets
- Algorithm
 - Let $k=1$
 - Generate $F_1 = \{\text{frequent 1-itemsets}\}$
 - Repeat until F_k is empty
 - **Candidate Generation**: Generate C_{k+1} from F_k
 - **Candidate Pruning**: Prune candidate itemsets in C_{k+1} containing subsets of length k that are infrequent
 - **Support Counting**: Count the support of each candidate in C_{k+1} by scanning the DB
 - **Candidate Elimination**: Eliminate candidates in C_{k+1} that are infrequent, leaving only those that are frequent $\Rightarrow F_{k+1}$

Illustrating Apriori Principle

1-itemsets

Item	Count
Bread	
Coke	
Milk	
Beer	
Diaper	
Eggs	

x



x

2-itemsets

Itemset	Count
{Bread, Milk}	
{Bread, Beer}	
{Bread, Diaper}	
{Milk, Beer}	
{Milk, Diaper}	
{Beer, Diaper}	

x

x

x



3-itemsets

Itemset	Count
{Bread, Diaper, Milk}	

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Minimum Support = 3

If every subset is considered,

$${}^6C_1 + {}^6C_2 + {}^6C_3$$

$$6 + 15 + 20 = 41$$

With support-based pruning,

$$6 + 6 + 1 = 13$$

- ขั้นตอนวิธี Apriori มีหลักเกณฑ์ว่า subset ของ k-itemset ทุกตัวจะต้องเป็น large k-1 itemset มิฉะนั้นจะไม่สามารถเป็น large itemset ในระดับต่อไปได้ ดังนั้นจะตัด k-itemset นั้นๆ ออกไปโดยไม่ต้องนำมานับ
- {Bread, Diaper, Milk} เป็น 3-itemset ได้ เพราะ {Bread, Diaper}, {Bread, Milk}, {Bread, Milk} เป็น large 2-itemset ทุกตัว

Candidate Generation: $F_{k-1} \times F_{k-1}$ Method

- Merge two frequent $(k-1)$ -itemsets if their first $(k-2)$ items are identical
- $F_3 = \{ABC, ABD, ABE, ACD, BCD, BDE, CDE\}$
 - Merge(**ABC**, **ABD**) = **AB**CD
 - Merge(**ABC**, **ABE**) = **AB**CE
 - Merge(**ABD**, **ABE**) = **AB**DE
- $C_4 = \{ABCD, ABCE, ABDE\}$ is the set of candidate 4-itemsets generated
- Do not merge(**ABD**, **ACD**) because they share only prefix of length 1 instead of length 2

Candidate Pruning

- $F_3 = \{ABC, ABD, ABE, ACD, BCD, BDE, CDE\}$
- $C_4 = \{ABCD, ABCE, ABDE\}$ is the set of candidate 4-itemsets generated
- Candidate pruning
 - Prune ABCE because ACE and BCE are infrequent
 - Prune ABDE because ADE is infrequent
- After candidate pruning: $C_4 = \{ABCD\}$

Alternate $F_{k-1} \times F_{k-1}$ Method

- Merge two frequent $(k-1)$ -itemsets if the last $(k-2)$ items of the first one is identical to the first $(k-2)$ items of the second.
- $F_3 = \{ABC, ABD, ABE, ACD, BCD, BDE, CDE\}$
 - Merge(**ABC**, **BCD**) = A**BCD**
 - Merge(**ABD**, **BDE**) = A**BDE**
 - Merge(A**CD**, **CDE**) = A**CDE**
 - Merge(**BCD**, **CDE**) = B**CDE**
- $C_4 = \{ABCD, ABDE, ACDE, BCDE\}$
- **Candidate pruning**
 - Prune ABDE because ADE is infrequent
 - Prune ACDE because ACE and ADE are infrequent
 - Prune BCDE because BCE is infrequent
- After candidate pruning: $C_4 = \{ABCD\}$

Example 2

ดังนั้น large itemset
ชุดแรกที่เราได้ก็คือ
ขนมปัง เบียร์ ผ้าอ้อม ไช้



เรียก large itemset ชุดนี้ว่า 1-large
itemset (เพราะมันคือการนับสินค้าที่ละตัว
ไม่ได้ดูว่ามันเกิดร่วมกับสินค้าตัวอื่นหรือไม่)

Transaction ID	Items
001	ขนมปัง ผ้าอ้อม นม
002	เบียร์ ผ้าอ้อม ไช้
003	ขนมปัง เบียร์ ผ้าอ้อม ไช้
004	เบียร์ ไช้

Minimum Support =50%

1 - itemset	Count
ขนมปัง	
เบียร์	
ผ้าอ้อม	
นม	
ไช้	

C_1

Candidate 1-itemsets

Large 1-itemset	Count

Example 2

large 1-itemset ที่ทำได้ จะถูกนำไป
ผสมกันเพื่อสร้างเป็น 2-itemset
เรียกขั้นตอนนี้ว่าการ join



จากนั้นเราก็ทำนับจำนวนรายการที่เกิดขึ้นเหมือน
ขั้นตอนที่แล้ว เพื่อหา 2-large itemset

C_2

Large 1-itemset	Count
ขนมปัง	2
เบียร์	3
ผ้าอ้อม	3
ไข่	3



Candidate 2-itemsets

2 - itemset	Count
ขนมปัง เบียร์	
ขนมปัง ผ้าอ้อม	
ขนมปัง ไข่	
เบียร์ ผ้าอ้อม	
เบียร์ ไข่	
ผ้าอ้อม ไข่	




Large 2-itemset	Count

ไม่มีนม
อยู่ในนี้แล้ว



แบบนี้ก็ลดจำนวนรายการที่ต้องนับ
ลงไปได้ 4 บรรทัด
เพราะไม่ต้องนับ (นม ขนมปัง),
(นม เบียร์), (นม ผ้าอ้อม), (นม ไข่)

Example 2



- ขั้นตอนวิธี Apriori มีหลักเกณฑ์ว่า subset ของ k-itemset ทุกตัวจะต้องเป็น large k-1 itemset มิฉะนั้นจะไม่สามารถเป็น large itemset ในระดับต่อไปได้ ดังนั้นจะตัด k-itemset นั้นๆ ออกไปโดยไม่ต้องนำมานับ
- จากตัวอย่างนี้ {ขนมปัง ผ้าอ้อม ไช้} เป็น 3-itemset เพราะ {ขนมปัง ผ้าอ้อม}, {ขนมปัง ไช้}, {ผ้าอ้อม ไช้} เป็น large 2-itemset ทุกตัว
- {ขนมปัง ผ้าอ้อม ไช้} ถูก prune ทิ้ง เนื่องจากในกรณีนี้ {ขนมปัง ไช้} ไม่ได้เป็น large 2-itemset

Transaction ID	Items
001	ขนมปัง ผ้าอ้อม ไช้
002	เบียร์ ผ้าอ้อม ไช้
003	ขนมปัง เบียร์ ผ้าอ้อม ไช้
004	เบียร์ ไช้

1 - itemset	Count
ขนมปัง	2
เบียร์	3
ผ้าอ้อม	3
นม	1
ไช้	3

Large 1-itemset	Count
ขนมปัง	2
เบียร์	3
ผ้าอ้อม	3
ไช้	3


3 - itemset	Count
เบียร์ ผ้าอ้อม ไช้	2

Large 3-itemset	Count
เบียร์ ผ้าอ้อม ไช้	2

Large 2-itemset	Count
ขนมปัง ผ้าอ้อม	2
เบียร์ ผ้าอ้อม	2
เบียร์ ไช้	3
ผ้าอ้อม ไช้	2

2 - itemset	Count
ขนมปัง เบียร์	1
ขนมปัง ผ้าอ้อม	2
ขนมปัง ไช้	1
เบียร์ ผ้าอ้อม	2
เบียร์ ไช้	3
ผ้าอ้อม ไช้	2

ทำแบบนี้ซ้ำไปเรื่อยๆ ก็จะสามารถหา
large itemset ทั้งหมดได้



Individual Assignment

จากตารางข้อมูลรายการซื้อสินค้าจำนวน 6 รายการ จงแสดงวิธีการสร้างกฎความสัมพันธ์ด้วย Apriori Algorithm โดยกำหนดค่า minimum support = 2

Transaction ID	Items Bought
1	Bread, Coffee, Sandwich
2	Bread, Coffee
3	Bread, Coke, Chips
4	Chips, Coke
5	Chips, Sandwich
6	Bread, Coke, Chips

Individual Assignment

กำหนดค่า minimum support = 30%

Transaction ID	Items Bought
1	Laptop, Printer, Tablet, Headset
2	Printer, Monitor, Tablet
3	Laptop, Printer, Tablet, Headset
4	Laptop, Monitor, Tablet, Headset
5	Printer, Monitor, Tablet, Headset
6	Printer, Tablet, Headset
7	Monitor, Tablet
8	Laptop, Printer, Monitor
9	Laptop, Tablet, Headset
10	Printer, Tablet

Example 3

Transaction ID	Items
1	Apple, Cereal, Diapers
2	Beer, Cereal, Eggs
3	Apple, Beer, Cereal, Eggs
4	Beer, Eggs

กำหนดค่า minimum support = 50%

Items	Transaction ID			
	1	2	3	4
Apple	1	0	1	0
Beer	0	1	1	1
Cereal	1	1	1	0
Diapers	1	0	0	0
Eggs	0	1	1	1

Example 3

Items	Transaction ID				Support
	1	2	3	4	
Apple	1	0	1	0	$2/4 = 50\%$
Beer	0	1	1	1	$3/4 = 75\%$
Cereal	1	1	1	0	$3/4 = 75\%$
Diapers	1	0	0	0	$1/4 = 25\%$ X
Eggs	0	1	1	1	$3/4 = 75\%$

- จากค่า support ที่คำนวณได้ จะเห็นว่า Diapers มีค่า support ต่ำกว่าค่า minimum support
- ดังนั้น Diapers จะถูกตัดออกและไม่นำไปพิจารณาสร้างเป็น itemset ที่มีความยาว 2
- เรียก Apple, Beer, Cereal และ Eggs ว่า frequent itemset หรือ large itemset

Example 3

- นำ frequent itemset ที่ได้ มาสร้างเป็น itemset ที่มีความยาว 2 โดยใช้การ join ได้เป็น {Apple, Beer}, {Apple, Cereal}, {Apple, Eggs}, {Beer, Cereal}, {Cereal, Eggs}
- เนื่องจากเป็นเซต (set) ลำดับของข้อมูลจึงไม่มีผล {Apple, Beer} = {Beer, Apple}

Itemset	Transaction ID				Support
	1	2	3	4	
{Apple, Beer}	0	0	1	0	1/4 = 25% X
{Apple, Cereal}	1	0	1	0	2/4 = 50%
{Apple, Eggs}	0	0	1	0	1/4 = 25% X
{Beer, Cereal}	0	1	1	0	2/4 = 50%
{Beer, Eggs}	0	1	1	1	3/4 = 75%
{Cereal, Eggs}	0	1	1	0	2/4 = 50%

Example 3

- จากหลักเกณฑ์ของ Apriori ที่ระบุว่า **subset ของ k-itemset ทุกตัวจะต้องเป็น frequent k-1 itemset มิฉะนั้นจะไม่สามารถเป็น frequent itemset ในระดับต่อไปได้** ดังนั้นจะตัด k-itemset นั้นๆ ออกไปโดยไม่ต้องนำมานับ
- สร้าง itemset ที่มีความยาวเท่ากับ 3 ได้ {Beer, Cereal, Eggs} ซึ่งเกิดจากการ join {Beer, Cereal}, {Beer, Eggs} และ {Cereal, Eggs} แต่ไม่สามารถ join {Apple, Cereal} และ {Beer, Cereal} ได้ ดังนั้นในขั้นตอนนี้จะเหลือเพียงแค่ itemset เดียวคือ {Beer, Cereal, Eggs} และเป็น frequent itemset

{ Apple , Cereal }
{ Beer , Cereal }
{ Beer , Eggs }
{ Cereal , Eggs }

Items	Transaction ID				Support
	1	2	3	4	
{ Beer , Cereal , Eggs }	0	1	1	0	2/4 = 50%

Example 3

- เมื่อไม่สามารถสร้าง itemset ที่มีความยาวมากขึ้นกว่านี้ได้อีก ขั้นตอนการหา frequent itemset จึงหยุด และได้ frequent itemsets ทั้งหมด

Frequent itemset	Support	Size
{Apple}	$2/4 = 50\%$	1
{Beer}	$3/4 = 75\%$	1
{Cereal}	$3/4 = 75\%$	1
{Eggs}	$3/4 = 75\%$	1
{Apple, Cereal}	$2/4 = 50\%$	2
{Beer, Cereal}	$2/4 = 50\%$	2
{Beer, Eggs}	$3/4 = 75\%$	2
{Cereal, Eggs}	$2/4 = 50\%$	2
{Beer, Cereal, Eggs}	$2/4 = 50\%$	3

Rule Generation

- พิจารณา frequent itemset ที่มีความยาวมากกว่า 2 item ขึ้นไปมาสร้างเป็นกฎความสัมพันธ์ เช่น {Apple, Cereal} จะสร้างกฎความสัมพันธ์ได้เป็น Apple $\Rightarrow$ Cereal เป็นต้น
- โดยกฎความสัมพันธ์ทั่วไปจะแสดงเป็น

LHS $\Rightarrow$ RHS

- โดยที่ LHS (Left Hand Side) แสดงรูปแบบของ itemset ด้านซ้ายของกฎความสัมพันธ์ และ RHS (Right Hand Side) แสดงรูปแบบของ itemset ด้านขวาของกฎความสัมพันธ์

Rule Generation

Frequent itemset	Support
{Apple}	2/4 = 50%
{Beer}	3/4 = 75%
{Cereal}	3/4 = 75%
{Eggs}	3/4 = 75%
{Apple, Cereal}	2/4 = 50%
{Beer, Cereal}	2/4 = 50%
{Beer, Eggs}	3/4 = 75%
{Cereal, Eggs}	2/4 = 50%
{Beer, Cereal, Eggs}	2/4 = 50%

Each frequent k -itemset, Y , can produce up to $2^k - 2$ association rules

Rule No.	Rule
1	Apple $\Rightarrow$ Cereal
2	Beer $\Rightarrow$ Eggs
3	Eggs $\Rightarrow$ Beer
4	Beer, Cereal $\Rightarrow$ Eggs
5	Cereal, Eggs $\Rightarrow$ Beer
6	Cereal $\Rightarrow$ Apple
7	Beer $\Rightarrow$ Cereal, Eggs
8	Eggs $\Rightarrow$ Beer, Cereal
9	Beer $\Rightarrow$ Cereal
10	Cereal $\Rightarrow$ Beer
11	Cereal $\Rightarrow$ Eggs
12	Eggs $\Rightarrow$ Cereal
13	Cereal $\Rightarrow$ Beer, Eggs
14	Beer, Eggs $\Rightarrow$ Cereal

ตัววัดประสิทธิภาพของกฎ

ในการพิจารณาว่ากฎความสัมพันธ์ที่สร้างได้ดีหรือไม่ จะต้องมิตัววัดประสิทธิภาพของกฎ นั่นคือ ค่า confidence และค่า lift

- ค่า confidence แสดงความเชื่อมั่นของกฎความสัมพันธ์ที่เมื่อรูปแบบ LHS เกิดขึ้นแล้วรูปแบบ RHS จะเกิดขึ้นด้วยเป็นจำนวนกี่เปอร์เซ็นต์ การคำนวณค่า confidence หาได้จาก

$$\text{confidence}(\text{LHS} \Rightarrow \text{RHS}) = \frac{\text{support}(\text{LHS}, \text{RHS})}{\text{support}(\text{LHS})}$$

โดยที่ support (LHS, RHS) คือ ค่า support ที่รูปแบบ LHS และ RHS เกิดขึ้นพร้อมๆ กัน ตัวอย่าง การหา confidence ของกฎ Apple => Cereal แสดงได้ดังนี้

$$\text{confidence}(\text{Apple} \Rightarrow \text{Cereal}) = \frac{\text{support}(\text{Apple}, \text{Cereal})}{\text{support}(\text{Apple})} = \frac{2/4}{2/4} = 100\%$$

$$\text{confidence}(\text{LHS} \Rightarrow \text{RHS}) = \frac{\text{support}(\text{LHS}, \text{RHS})}{\text{support}(\text{LHS})}$$

Frequent itemset	Support
{Apple}	2/4 = 50%
{Beer}	3/4 = 75%
{Cereal}	3/4 = 75%
{Eggs}	3/4 = 75%
{Apple, Cereal}	2/4 = 50%
{Beer, Cereal}	2/4 = 50%
{Beer, Eggs}	3/4 = 75%
{Cereal, Eggs}	2/4 = 50%
{Beer, Cereal, Eggs}	2/4 = 50%


Rule No.	Rule	Confidence
1	Apple $\Rightarrow$ Cereal	
2	Beer $\Rightarrow$ Eggs	
3	Eggs $\Rightarrow$ Beer	
4	Beer, Cereal $\Rightarrow$ Eggs	
5	Cereal, Eggs $\Rightarrow$ Beer	
6	Cereal $\Rightarrow$ Apple	
7	Beer $\Rightarrow$ Cereal, Eggs	
8	Eggs $\Rightarrow$ Beer, Cereal	
9	Beer $\Rightarrow$ Cereal	
10	Cereal $\Rightarrow$ Beer	
11	Cereal $\Rightarrow$ Eggs	
12	Eggs $\Rightarrow$ Cereal	
13	Cereal $\Rightarrow$ Beer, Eggs	
14	Beer, Eggs $\Rightarrow$ Cereal	

ตัววัดประสิทธิภาพของกฎ

ค่า Confidence เป็นตัววัดประสิทธิภาพสำหรับ Association Rule โดยเป็นตัวเลขที่แสดงแนวโน้มจะเป็นที่กลุ่มของสินค้า RHS จะถูกหยิบเข้าตะกร้าด้วย หลังจากที่ถูกกลุ่มของสินค้า LHS ถูกหยิบเข้าตะกร้าไปแล้ว หรืออาจกล่าวได้ว่า “หากเราพิจารณาเฉพาะตะกร้าการซื้อขายที่มีกลุ่มสินค้า LHS มีตะกร้าการซื้อขายที่มี RHS อยู่ด้วยเป็นสัดส่วนเท่าไร”

ในตัวอย่างร้านค้าของเรา หากพิจารณา $LHS = \{Cereal\}$ และ $RHS = \{Apple\}$ จะได้ว่า $Confidence(\{Cereal\} \Rightarrow \{Apple\}) = 2/3$ (ภายใน 3 ตะกร้าที่มีการซื้อขาย Cereal มีจำนวน 2 ตะกร้าที่มีการซื้อขาย Apple ด้วย)

หาก RHS เป็นกลุ่มของสินค้าที่พบเจอในแทบทุกตะกร้าการซื้อขาย (a very frequent itemset) ไม่ว่า LHS จะเป็นกลุ่มของสินค้าใดก็ตาม $Confidence(LHS \Rightarrow RHS)$ จะมีค่าค่อนข้างสูงเสมอ ด้วยเหตุนี้ จึงมีอีกหนึ่งตัววัดประสิทธิภาพที่พิจารณาความถี่ในการพบกลุ่มของสินค้า RHS ร่วมกับค่า confidence ด้วย



ตัววัดประสิทธิภาพของกฎ

ค่า Lift เป็นตัววัดประสิทธิภาพสำหรับ Association Rule ที่ทำการเปรียบเทียบ ความน่าจะเป็นที่จะพบกลุ่มของสินค้า RHS ในตะกร้าที่มีการซื้อขายกลุ่มของสินค้า LHS กับ ความน่าจะเป็นที่จะพบกลุ่มของสินค้า RHS ในตะกร้าทั้งหมดคือ

- ค่าที่บ่งบอกว่าการเกิดรูปแบบ LHS และ RHS มีความสัมพันธ์กันแค่ไหน โดยถ้าค่า lift เป็น 1 แสดงว่ารูปแบบ LHS และ RHS ไม่ขึ้นต่อกัน (independent) ค่า lift คำนวณได้จาก

$$\text{lift}(\text{LHS} \Rightarrow \text{RHS}) = \frac{\text{support}(\text{LHS}, \text{RHS})}{\text{support}(\text{LHS}) \times \text{support}(\text{RHS})}$$

- ตัวอย่างของการหาค่า lift ของกฎ Apple => Cereal แสดงได้ดังนี้

$$\text{lift}(\text{Apple} \Rightarrow \text{Cereal}) = \frac{\text{support}(\text{Apple}, \text{Cereal})}{\text{support}(\text{Apple}) \times \text{support}(\text{Cereal})} = \frac{2/4}{2/4 \times 3/4} = 1.33$$

$$\text{lift}(\text{LHS} \Rightarrow \text{RHS}) = \frac{\text{support}(\text{LHS}, \text{RHS})}{\text{support}(\text{LHS}) \times \text{support}(\text{RHS})}$$

Frequent itemset	Support
{Apple}	2/4 = 50%
{Beer}	3/4 = 75%
{Cereal}	3/4 = 75%
{Eggs}	3/4 = 75%
{Apple, Cereal}	2/4 = 50%
{Beer, Cereal}	2/4 = 50%
{Beer, Eggs}	3/4 = 75%
{Cereal, Eggs}	2/4 = 50%
{Beer, Cereal, Eggs}	2/4 = 50%

Rule No.	Rule	Confidence	Lift
1	Apple $\Rightarrow$ Cereal	100%	
2	Beer $\Rightarrow$ Eggs	100%	
3	Eggs $\Rightarrow$ Beer	100%	
4	Beer, Cereal $\Rightarrow$ Eggs	100%	
5	Cereal, Eggs $\Rightarrow$ Beer	100%	
6	Cereal $\Rightarrow$ Apple	67%	
7	Beer $\Rightarrow$ Cereal, Eggs	67%	
8	Eggs $\Rightarrow$ Beer, Cereal	67%	
9	Beer $\Rightarrow$ Cereal	67%	
10	Cereal $\Rightarrow$ Beer	67%	
11	Cereal $\Rightarrow$ Eggs	67%	
12	Eggs $\Rightarrow$ Cereal	67%	
13	Cereal $\Rightarrow$ Beer, Eggs	67%	
14	Beer, Eggs $\Rightarrow$ Cereal	67%	

ตัววัดประสิทธิภาพของกฎ

ค่า Lift เปรียบเทียบให้เราว่า “ความน่าจะเป็นที่ลูกค้าจะหยิบกลุ่มสินค้า RHS หลังจากที่ถูกค้าหยิบกลุ่มสินค้า LHS ลงตะกร้าไปแล้ว เพิ่มหรือลดเป็นจำนวนกี่เท่าของความน่าจะเป็นที่ลูกค้าจะซื้อกลุ่มสินค้า RHS โดยปกติ” หากค่า Lift > 1 (เท่า) แสดงว่า การที่ภายในตะกร้ามีกลุ่มสินค้า LHS อยู่ ทำให้ความน่าจะเป็นที่ลูกค้าจะหยิบ RHS มาใส่ตะกร้ามีค่าเพิ่มขึ้น

การมีอยู่ของกลุ่มสินค้า LHS ในตะกร้า ยก (lift) ค่าความน่าจะเป็นในการซื้อกลุ่มสินค้า RHS

{Beer, Cereal}	$2/4 = 50\%$
{Beer, Eggs}	$3/4 = 75\%$
{Cereal}	$3/4 = 75\%$

Eggs $\Rightarrow$ Beer, Cereal	67%	1.33
Cereal $\Rightarrow$ Beer, Eggs	67%	0.89
Beer, Eggs $\Rightarrow$ Cereal	67%	0.89

ในตัวอย่างร้านค้าของเรา จะเห็นว่า การมี Eggs ในตะกร้า เพิ่มความน่าจะเป็นที่ลูกค้าจะหยิบ {Beer, Cereal} ด้วย จาก 0.5 ไป 0.67 (Lift = 1.33) ในทางกลับกัน การมี {Beer, Eggs} ในตะกร้าไม่ได้เพิ่มความน่าจะเป็นที่ลูกค้าจะหยิบ Cereal ด้วย (Lift = 0.89)

ค่า Lift สามารถใช้ช่วยในการตัดสินใจเรื่อง การจัดวางตำแหน่งของสินค้าบนชั้นวางของ หรือการแนะนำสินค้าเพิ่มเติมในระหว่างที่ลูกค้ากำลังซื้อสินค้าออนไลน์ หรือการออกโปรโมชั่นกลุ่มสินค้าใหม่ ๆ ได้

Factors Affecting Complexity of Apriori

- Choice of minimum support threshold
- Dimensionality (number of items) of the data set
- Size of database
- Average transaction width

Factors Affecting Complexity of Apriori

- Choice of minimum support threshold
 - lowering support threshold results in more frequent itemsets
 - this may increase number of candidates and max length of frequent itemsets
- Dimensionality (number of items) of the data set
- Size of database
- Average transaction width

Factors Affecting Complexity of Apriori

- Choice of minimum support threshold
 - lowering support threshold results in more frequent itemsets
 - this may increase number of candidates and max length of frequent itemsets

Item	Count
Bread	4
Coke	2
Milk	4
Beer	3
Diaper	4
Eggs	1

Minimum Support = 3

If every subset is considered,
 ${}^6C_1 + {}^6C_2 + {}^6C_3$
 $6 + 15 + 20 = 41$
With support-based pruning,
 $6 + 6 + 4 = 16$

Minimum Support = 2

If every subset is considered,
 ${}^6C_1 + {}^6C_2 + {}^6C_3 + {}^6C_4$
 $6 + 15 + 20 + 15 = 56$

Factors Affecting Complexity of Apriori

- Dimensionality (number of items) of the data set
 - More space is needed to store support count of itemsets
 - if number of frequent itemsets also increases, both computation and I/O costs may also increase
- Size of database
 - run time of algorithm increases with number of transactions
- Average transaction width
 - transaction width increases the max length of frequent itemsets
 - number of subsets in a transaction increases with its width, increasing computation time for support counting