



## ส่งหัวข้อโครงการ

เรื่อง Olytics

## จัดทำโดย

|              |                |                       |
|--------------|----------------|-----------------------|
| นายทวีวัฒน์  | सानนท์กุลวัฒน์ | รหัสนักศึกษา 67070005 |
| นายธิตีวัฒน์ | สมพันธ์เดชสกุล | รหัสนักศึกษา 67070080 |
| นายภคพล      | โพธิวร         | รหัสนักศึกษา 67070124 |
| นายภัทรพล    | เพ็ชรรัตน์     | รหัสนักศึกษา 67070127 |
| นายภูวาริช   | กองจร          | รหัสนักศึกษา 67070140 |

## เสนอ

ผศ. ดร. พัฒนพงษ์ ฉันทมิตรโอภาส

ผศ. ดร. ลภัส ประดิษฐ์ทัศนีย์

รายงานเล่มนี้เป็นส่วนหนึ่งของวิชา

CLOUD TECHNOLOGY INFRASTRUCTURE

คณะเทคโนโลยีสารสนเทศ สาขาวิทยาการข้อมูลและวิเคราะห์เชิงธุรกิจ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

ภาคเรียนที่ 1 ปีการศึกษา 2569

## ที่มาของเรื่อง

ในปัจจุบันธุรกิจอีคอมเมิร์ซมีการเติบโตอย่างรวดเร็ว ส่งผลให้เกิดข้อมูลจำนวนมากมหาศาลจากการทำธุรกรรมในแต่ละวัน ทั้งข้อมูลคำสั่งซื้อ ข้อมูลสินค้า ข้อมูลลูกค้า ข้อมูลผู้ขาย การชำระเงิน ตลอดจนความคิดเห็นและคะแนนรีวิวจากผู้ซื้อ ข้อมูลเหล่านี้มักถูกจัดเก็บกระจายอยู่ในหลายตารางและหลายระบบ ซึ่งถูกออกแบบมาเพื่อรองรับการทำธุรกรรม (Transactional System) เป็นหลัก จึงไม่เหมาะกับการนำมาวิเคราะห์เชิงลึก เนื่องจากการเชื่อมโยงข้อมูลจำนวนมากทำได้ช้าและส่งผลกระทบต่อประสิทธิภาพของระบบงานหลัก

ด้วยเหตุนี้ แนวคิดเรื่องคลังข้อมูล (Data Warehouse) จึงถูกนำมาใช้เพื่อรวบรวมข้อมูลจากหลายแหล่งมาจัดเก็บในรูปแบบที่เหมาะสมต่อการวิเคราะห์ อย่างไรก็ตาม การจัดตั้งคลังข้อมูลด้วยเครื่องมือช่วยภายในองค์กรจำเป็นต้องใช้เงินลงทุนสูงและต้องดูแลรักษาอย่างต่อเนื่อง ซึ่งเป็นข้อจำกัดสำคัญสำหรับผู้เริ่มต้นศึกษา

ผู้จัดทำจึงมีแนวคิดในการพัฒนาระบบคลังข้อมูลบนบริการคลาวด์ของ Amazon Web Services (AWS) โดยนำชุดข้อมูลจริงจากธุรกิจอีคอมเมิร์ซ Olist ประเทศบราซิล ซึ่งประกอบด้วยคำสั่งซื้อกว่า 100,000 รายการ ระหว่างปี ค.ศ. 2016 ถึง 2018 มาผ่านกระบวนการนำเข้า แปลง และจัดเก็บในรูปแบบ Star Schema เพื่อแสดงให้เห็นว่าการสร้างคลังข้อมูลสามารถทำได้โดยไม่ต้องลงทุนกับฮาร์ดแวร์จริง อีกทั้งยังสามารถปรับขยายทรัพยากรได้ตามความต้องการ และคิดค่าใช้จ่ายตามการใช้งานจริง ซึ่งเป็นการใช้ทรัพยากรอย่างคุ้มค่าและยั่งยืน

## วัตถุประสงค์

- เพื่อศึกษาและออกแบบสถาปัตยกรรมคลังข้อมูล (Data Warehouse) บนระบบคลาวด์ โดยใช้บริการของ AWS
- เพื่อพัฒนาระบบการ ETL สำหรับนำเข้าและแปลงข้อมูลจากไฟล์ต้นทางให้อยู่ในรูปแบบ Star Schema ที่เหมาะสมต่อการวิเคราะห์
- เพื่อแสดงให้เห็นว่าการจัดเก็บและประมวลผลข้อมูลขนาดใหญ่สามารถดำเนินการได้โดยไม่ต้องมีฮาร์ดแวร์จริง
- เพื่อเปรียบเทียบประสิทธิภาพของการสืบค้นข้อมูลระหว่าง Amazon Athena ซึ่งสืบค้นข้อมูลจาก S3 โดยตรง กับ Amazon Redshift ซึ่งเป็นคลังข้อมูลโดยเฉพาะ
- เพื่อนำเสนอผลการวิเคราะห์ข้อมูลเชิงธุรกิจในรูปแบบ Dashboard ที่เข้าใจง่ายและนำไปใช้ประกอบการตัดสินใจได้

## ประโยชน์ที่คาดว่าจะได้รับ

1. ได้ระบบคลังข้อมูลที่สามารถรองรับการวิเคราะห์ข้อมูลคำสั่งซื้อกว่า 100,000 รายการได้อย่างมีประสิทธิภาพ
2. เข้าใจหลักการออกแบบ Star Schema รวมถึงการแยก Fact Table และ Dimension Table ในการทำคลังข้อมูล
3. เข้าใจกระบวนการทำงานของ ETL Pipeline บนระบบคลาวด์ ตั้งแต่การนำเข้าข้อมูลจนถึงการนำไปแสดงผล
4. ได้ข้อมูลเชิงลึกทางธุรกิจ เช่น แนวโน้มยอดขายรายเดือน หมวดสินค้าที่ได้รับความนิยม และความสัมพันธ์ระหว่างระยะเวลาจัดส่งกับคะแนนรีวิวของลูกค้า
5. สามารถประเมินค่าใช้จ่ายและเลือกใช้บริการคลาวด์ได้อย่างเหมาะสมกับปริมาณงาน

## ขอบเขตโครงการ


1. ใช้ชุดข้อมูล Brazilian E-Commerce Public Dataset by Olist ซึ่งเป็นข้อมูลเชิงพาณิชย์จริงที่ผ่านการปกปิดตัวตนแล้ว ประกอบด้วยตารางข้อมูลหลัก 8 ตาราง และตารางแปลชื่อหมวดหมู่สินค้าอีก 1 ตาราง รวมทั้งสิ้น 9 ไฟล์
2. จัดเก็บข้อมูลดิบบน Amazon S3 โดยแบ่งพื้นที่จัดเก็บออกเป็น Raw Zone และ Curated Zone
3. ทำความสะอาดข้อมูลด้วย AWS Glue DataBrew และแปลงข้อมูลด้วย AWS Glue ETL Job
4. ออกแบบคลังข้อมูลในรูปแบบ Star Schema ประกอบด้วย Fact Table 1 ตาราง และ Dimension Table 5 ตาราง ได้แก่ ลูกค้า สินค้า ผู้ขาย เวลา และการชำระเงิน
5. จัดเก็บคลังข้อมูลบน Amazon Redshift และสร้าง Dashboard สำหรับแสดงผลการวิเคราะห์
6. ตั้งค่าให้กระบวนการ ETL ทำงานโดยอัตโนมัติเมื่อมีไฟล์ข้อมูลใหม่เข้าสู่ระบบ ด้วย AWS Lambda และ Amazon EventBridge
7. ระบบนี้มุ่งเน้นการวิเคราะห์ข้อมูลย้อนหลัง (Batch Processing) ไม่ครอบคลุมการประมวลผลข้อมูลแบบทันที (Real-time Streaming)
8. ระบบพัฒนาและทดสอบภายใต้ข้อจำกัดของ AWS Academy Learner Lab ซึ่งจำกัดการใช้งานเฉพาะ Region us-east-1 และ us-west-2

## บริการของ AWS ที่ใช้ในโครงการ

ตารางต่อไปนี้จะแสดงบริการของ AWS ที่นำมาใช้ในโครงการ พร้อมทั้งหน้าที่และข้อจำกัดภายใต้สภาพแวดล้อม AWS Academy Learner Lab

| บริการของ AWS         | หน้าที่ในระบบ                                                                                              | ข้อจำกัดใน Learner Lab                                                        |
|-----------------------|------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|
| Amazon S3             | จัดเก็บไฟล์ข้อมูลดิบ (Raw Zone) และข้อมูลที่ผ่านการแปลงแล้ว (Curated Zone) ทำหน้าที่เป็น Data Lake ของระบบ | ใช้งานได้ตามปกติ สามารถใช้ LabRole ได้                                        |
| AWS Glue DataBrew     | ทำความสะอาดข้อมูล เช่น ลบ ข้อมูลซ้ำ จัดการค่าว่าง และ ตรวจสอบคุณภาพข้อมูลเบื้องต้น                         | ใช้ LabRole ได้ ไม่มีข้อจำกัด พิเศษ                                           |
| AWS Glue (ETL Job)    | แปลงข้อมูลจากไฟล์ต้นทางทั้ง 9 ไฟล์ให้อยู่ในรูปแบบ Star Schema และคำนวณค่าเพิ่มเติม เช่น ระยะเวลาจัดส่ง     | Worker type: G.1X หรือ Standard, จำนวน Worker สูงสุด 10, Concurrency สูงสุด 1 |
| AWS Glue Data Catalog | จัดเก็บ Metadata และ Schema ของข้อมูลใน S3 เพื่อให้บริการอื่น เรียกใช้ได้                                  | ใช้งานร่วมกับ Glue Crawler ได้ ตามปกติ                                        |
| Amazon Redshift       | ทำหน้าที่เป็นคลังข้อมูล (Data Warehouse) จัดเก็บ Fact และ Dimension Table สำหรับการ วิเคราะห์              | รองรับเฉพาะ ra3.large และคลัสเตอร์ขนาดสูงสุด 2 Instance                       |

|                    |                                                                                    |                                                                                     |
|--------------------|------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|
| Amazon Athena      | ใช้ Query ข้อมูลใน S3 โดยตรงแบบ Serverless เพื่อเปรียบเทียบประสิทธิภาพกับ Redshift | ใช้ LabRole ได้ ไม่มีข้อจำกัดพิเศษ                                                  |
| AWS Lambda         | ตรวจจับไฟล์ใหม่ที่เข้ามาใน S3 และสั่งให้ ETL Pipeline ทำงานโดยอัตโนมัติ            | รันพร้อมกันได้สูงสุด 10 Execution Environment                                       |
| Amazon EventBridge | ตั้งเวลาให้ Pipeline ทำงานตามรอบที่กำหนด และเชื่อมเหตุการณ์ระหว่างบริการ           | ใช้ LabRole ได้                                                                     |
| Amazon EC2         | ติดตั้งเครื่องมือแสดงผล Dashboard จากภายนอก เช่น Metabase หรือ Apache Superset     | รองรับ nano ถึง large เท่านั้น, รันพร้อมกันไม่เกิน 9 Instance และรวมไม่เกิน 32 vCPU |
| Amazon CloudWatch  | ติดตามการทำงานของ ETL Job และเก็บ Log เพื่อตรวจสอบข้อผิดพลาด                       | ใช้งานได้ตามปกติ                                                                    |
| AWS IAM (LabRole)  | กำหนดสิทธิ์ให้บริการต่าง ๆ เข้าถึงทรัพยากรระหว่างกันได้                            | ไม่สามารถสร้าง User, Group หรือ Role ใหม่ได้ ต้องใช้ LabRole ที่เตรียมไว้           |



หมายเหตุ : อาจมีการเปลี่ยนแปลงในภายหลัง