


04

K-Nearest Neighbors (KNN)

การจำแนกประเภทด้วยวิธีเพื่อนบ้านที่ใกล้ที่สุด



Types of Machine Learning




Classification



- กระบวนการสร้างโมเดลเพื่อจำแนกข้อมูลใหม่ ให้อยู่ในกลุ่มที่กำหนดมาให้จากกลุ่มตัวอย่างข้อมูลเดิม
- ข้อมูลที่ใช้ในการสร้างโมเดลเราจะเรียกว่า training data ซึ่งจะประกอบด้วย
 - attribute ทั่วไป (หรือตัวแปรต้นในทางสถิติ)
 - attribute ประเภท label หรือ class คำตอบที่เราสนใจให้โมเดลทำนายออกมา (หรือตัวแปรตามในทางสถิติ)

Training Data

- spam e-mail classification
- หา keyword ที่ใช้บ่งบอกว่าเป็น spam e-mail




ID	Text	Type
1	Please call our customer service representative on FREE PHONE 0800 145 4742 between 9am-11pm as you have WON a guaranteed £1000 cash	spam
2	You have won \$1,000 cash or a \$2,000 prize! To claim, call 09050000327	spam
3	I'm gonna be home soon and I don't want to talk about this stuff anymore tonight	normal
4	Is that seriously how you spell his name?	normal
5	Double mins and txts 4 6months FREE Bluetooth on Orange. Available on Sony, Nokia Motorola phones.	spam



keywords				
ID	Free	Won	Cash	Type
1	Y	Y	Y	spam
2	N	Y	Y	spam
3	N	N	N	normal
4	N	N	N	normal
5	Y	N	N	spam
6	Y	N	N	spam
7	N	N	N	normal
8	N	Y	N	spam
9	N	N	N	normal
10	N	N	N	normal

Application

- Credit card Approvals



- Credit card fraud detection




Application

- Customer Churn Prediction




- Autonomous Vehicles



Classification Algorithms

- K-Nearest Neighbor (KNN)
- Decision Trees
- Neural Networks
- Ensemble Classifier

Basic Idea of Nearest Neighbor



Similarity/Distance between Data Items

- each data item is represented with a set of attributes



John:
Age = 35
Income = 35K
No. of credit cards = 3



Susan:
Age = 22
Income = 50K
No. of credit cards = 2

- “Closeness / Nearest” is defined in terms of the distance between two data items

$$d(p, q) = d(q, p) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \dots + (q_n - p_n)^2} = \sqrt{\sum_{i=1}^n (q_i - p_i)^2}$$

$$d(\text{John}, \text{Susan}) = \sqrt{(35 - 22)^2 + (35 - 50)^2 + (3 - 2)^2} = 19.87$$

KNN Classifier

บริษัทอยากรทำนายว่า ลูกค้าจะซื้อสินค้า (Buy) หรือ ไม่ซื้อ (Not Buy) โดยดูจาก

- Attribute: อายุ (Age), รายได้ (Income), คะแนนความสนใจในสินค้า (Interest Score)
- กำหนด $k=3$

ลูกค้า	Age	Income	Interest	Result
A	22	40	5	Not Buy
B	25	42	6	Not Buy
C	24	38	7	Not Buy
D	30	50	5	Buy
E	28	48	6	Buy
F	29	46	7	Buy
X	26	44	6	?
Y	27	40	5	?

KNN Classifier

1) เลือก Distance ที่น้อยที่สุด
มา 3 ตัว (ตามจำนวน k)

ลูกค้า	(Age, Inc, Int)	Result	Distance
A	(22, 40, 5)	Not Buy	$\sqrt{[(22-26)^2 + (40-44)^2 + (5-6)^2]} = \sqrt{33} \approx 5.74$
B	(25, 42, 6)	Not Buy	$\sqrt{[(25-26)^2 + (42-44)^2 + (6-6)^2]} = \sqrt{5} \approx 2.24$
C	(24, 38, 7)	Not Buy	$\sqrt{[(2)^2 + (6)^2 + (1)^2]} = \sqrt{41} \approx 6.40$
D	(30, 50, 5)	Buy	$\sqrt{[(4)^2 + (6)^2 + (1)^2]} = \sqrt{53} \approx 7.28$
E	(28, 48, 6)	Buy	$\sqrt{[(2)^2 + (4)^2 + (0)^2]} = \sqrt{20} \approx 4.47$
F	(29, 46, 7)	Buy	$\sqrt{[(3)^2 + (2)^2 + (1)^2]} = \sqrt{14} \approx 3.74$
X	(26, 44, 6)	Buy	


2) Neighbors ที่เลือกมา มี Result เป็น Buy=2, Not Buy=1
ดังนั้น ผล vote ของ X ออกมาเป็น Buy

KNN Classifier

ลูกค้า	(Age, Inc, Int)	Result	Distance
A	(22, 40, 5)	Not Buy	$\sqrt{[25 + 0 + 0]} = \sqrt{25} = 5.00$
B	(25, 42, 6)	Not Buy	$\sqrt{[4 + 4 + 1]} = \sqrt{9} = 3.00$
C	(24, 38, 7)	Not Buy	$\sqrt{[9 + 4 + 4]} = \sqrt{17} \approx 4.12$
D	(30, 50, 5)	Buy	$\sqrt{[9 + 100 + 0]} = \sqrt{109} \approx 10.44$
E	(28, 48, 6)	Buy	$\sqrt{[1 + 64 + 1]} = \sqrt{66} \approx 8.12$
F	(29, 46, 7)	Buy	$\sqrt{[4 + 36 + 4]} = \sqrt{44} \approx 6.63$
Y	(27, 40, 5)	Not Buy	


KNN Classifier

0. Look at the data



Say you want to classify the grey point into a class. Here, there are three potential classes - lime green, green and orange.

1. Calculate distances



Start by calculating the distances between the grey point and all other points.

2. Find neighbours

Point Distance	
 ...  2.1	→ 1st NN
 ...  2.4	→ 2nd NN
 ...  3.1	→ 3rd NN
 ...  4.5	→ 4th NN

Next, find the nearest neighbours by ranking points by increasing distance. The nearest neighbours (NNs) of the grey point are the ones closest in dataspace.

3. Vote on labels

Class	# of votes	
	2	➔ Class  wins the vote! Point  is therefore predicted to be of class  .
	1	
	1	

Vote on the predicted class labels based on the classes of the k nearest neighbours. Here, the labels were predicted based on the $k=3$ nearest neighbours.

Individual Assignment

กำหนดให้มีสัตว์ 8 ชนิด จำแนกจากคุณสมบัติที่สามารถบ่งบอกถึงสายพันธุ์ได้ ดังแสดงในตาราง

ต้องการหาหมวดหมู่ของสัตว์ปริศนา ด้วยวิธี 3-NN

	ออกลูกเป็นตัว	ออกลูกเป็นไข่	เลี้ยงลูกด้วยนม	มีขนตามร่างกาย	ผิวหนังหรือมีเกล็ด	สัตว์เลือดอุ่น	สัตว์เลือดเย็น	อยู่ทั้งบกและน้ำ	หายใจด้วยเหงือก	
กบ		1					1	1		สัตว์ครึ่งบกครึ่งน้ำ
เปิด		1		1		1		1		สัตว์จำพวกนก
ค่างคาว	1		1	1						สัตว์เลี้ยงลูกด้วยนม
งู		1			1		1			สัตว์เลื้อยคลาน
ปลาแซลมอล		1			1		1		1	สัตว์จำพวกปลา
จระเข้		1			1		1			สัตว์เลื้อยคลาน
แมว	1		1	1		1				สัตว์เลี้ยงลูกด้วยนม
นกกระจอกเทศ		1		1		1				สัตว์จำพวกนก
สัตว์ปริศนา			1	1		1				???

Individual Assignment

จากชุดข้อมูลของสัตว์ปริศนา คำนวณ Euclidean Distance และหาหมวดหมู่ของสัตว์ปริศนา ด้วยวิธี 3-NN ได้ดังนี้

- $d_{\text{กบ}}$ = $\sqrt{6}$
- $d_{\text{เป็ด}}$ = $\sqrt{3}$
- $d_{\text{ค้างคาว}}$ = $\sqrt{2}$
- $d_{\text{งู}}$ = $\sqrt{6}$
- $d_{\text{ปลาแซลมอล}}$ = $\sqrt{7}$
- $d_{\text{จระเข้}}$ = $\sqrt{6}$
- $d_{\text{แมว}}$ = $\sqrt{1}$
- $d_{\text{นกกระจอกเทศ}}$ = $\sqrt{2}$

วิธี 3-NN ก็คือการหาข้อมูลในชุดข้อมูลที่มีอยู่ที่มีระยะทางใกล้กับข้อมูลที่พิจารณามากที่สุด 3 อันดับแรกขึ้นมาพิจารณา เมื่อคำนวณระยะทางได้แล้วจะเห็นได้ว่าสัตว์ที่มีระยะทางใกล้สุดกับสัตว์ปริศนาคือ แมว ค้างคาว และ นกกระจอกเทศ โดยมีระยะทางจากสัตว์ปริศนาคือ $\sqrt{1}$, $\sqrt{2}$ และ $\sqrt{2}$ ตามลำดับ จากนั้นให้พิจารณาจากสายพันธุ์ของสัตว์ทั้ง 3 ชนิด โดยจากข้อมูลเบื้องต้นพบว่า

- แมว มีสายพันธุ์เป็น สัตว์เลี้ยงลูกด้วยนม
- ค้างคาว มีสายพันธุ์เป็น สัตว์เลี้ยงลูกด้วยนม
- นกกระจอกเทศ มีสายพันธุ์เป็น สัตว์จำพวกนก


โดยจะเห็นได้ว่าจากสัตว์ 3 ชนิด เป็นสายพันธุ์สัตว์เลี้ยงลูกด้วยนมอยู่ 2 ชนิด และเป็นสายพันธุ์สัตว์จำพวกนก อยู่ 1 ชนิด ดังนั้นจึงสรุปตามเสียงข้างมาก ก็คือ สัตว์ปริศนามีสายพันธุ์เป็นสัตว์เลี้ยงลูกด้วยนม

Choosing the value of k

- If k is too small, sensitive to noise points
- If k is too large, neighborhood may include points from other classes
- Rule of thumb:

$$k = \sqrt{N}$$

N: number of training points



DATASET

Training Dataset


Testing Dataset

Train

Test

Train Model

Evaluate Model



Testing set

Training set




y

Hours of Study	Hours of Sleep	Result
8	5	Success
10	8	Success
5	4	Success
3	12	Fail
5	7	Success
2	6	Fail
3	6	Fail
7	6	Success

80% FOR TRAINING/VALIDATION

20% FOR TESTING





Confusion Matrix



A performance measurement for classification problem

True Positive: You predicted positive and it's true.

True Negative: You predicted negative and it's true.

False Positive: You predicted positive and it's false.

False Negative: You predicted negative and it's false.



Predicted Values	Actual Values	
	Positive (1)	Negative (0)
Positive (1)	TP	FP
Negative (0)	FN	TN

Case 1

COVID 19 = 1



Healthy = 0



Cost of FN > Cost of FP

Actual

Predict

	Diagnosed COVID 19 (1)	Diagnosed Healthy (0)
COVID 19 (1)	✓ TP 	✗ FP
Healthy (0)	✗ FN 	✓ TN

Healthy predicted as sick

Sick predicted as healthy

Imagine that if we predict COVID-19 residents as healthy patients and they do not need to quarantine, there would be a massive number of COVID-19 infections. The cost of false negatives is much higher than the cost of false positives.

Case 2

Spam = 1

Not Spam = 0



Cost of FP > Cost of FN

		Actual	
		Spam (1)	Not Spam (0)
Predict	Spam (1)	 TP 	 FP  <i>Not spam predicted as spam</i>
	Not Spam (0)	 FN  <i>Spam predicted as not spam</i>	 TN 

Since missing important emails will clearly be more of a problem than receiving spam, we can say that in this case, FP will have a higher cost than FN.

Case 3

Bad Loan = 1

Good Loan = 0



Cost of FN > Cost of FP

Actual

Predict

	Bad Loan (1)	Good Loan (0)
Bad Loan (1)	 TP 	 FP 
Good Loan (0)	 FN 	 TN 

Good loan predicted as a bad loan

Bad loan predicted as a good loan

The banks would lose a bunch amount of money if the actual bad loans are predicted as good loans due to loans not being repaid. On the other hand, banks won't be able to make more revenue if the actual good loans are predicted as bad loans. Therefore, the cost of False Negatives is much higher than the cost of False Positives

Bad Loan = 1

Good Loan = 0



Testing set



Training set

Predict

Actual

	Bad Loan (1)	Good Loan (0)
Bad Loan (1)	✓ TP - 20 	✗ FP - 5 
Good Loan (0)	✗ FN - 20 	✓ TN - 115 

Accuracy: Out of the total prediction made, how many did we predict correctly?

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Classification Rate / Accuracy

$$\text{precision} = \frac{\text{tp}}{\text{tp} + \text{fp}}$$

$$\text{recall} = \frac{\text{tp}}{\text{tp} + \text{fn}}$$

$$\text{accuracy} = \frac{\text{tp} + \text{tn}}{\text{tp} + \text{tn} + \text{fp} + \text{fn}}$$

$$F_1 \text{ score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

In practice, the cost of false negatives is not the same as the cost of false positives, depending on the different specific cases. It is evident that not only should we calculate accuracy, but we should also evaluate our model using other metrics, for example, **Recall** and **Precision**.

Case 1



COVID 19/ Healthy

Cost of **FN** > Cost of **FP**

Recall

$$\text{recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

Case 2



Spam/Not Spam

Cost of **FP** > Cost of **FN**

Precision

$$\text{precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

Case 3



Good/Bad loan

Cost of **FN** > Cost of **FP**

Recall

$$\text{recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

Bad Loan = 1

Good Loan = 0



Cost of FN > Cost of FP

Predict

	Actual	
	Bad Loan (1)	Good Loan (0)
Bad Loan (1)	✓ TP - 20 👎	✗ FP - 5 👎
Good Loan (0)	✗ FN - 20 👍	✓ TN - 115 👍

Bad loan predicted as a good loan

Precision: Out of the loan that is predicted as a bad loan, how many did we classify correctly?

$$\begin{aligned} \text{Precision} &= \frac{TP}{TP + FP} \\ &= \frac{20}{20+5} = 0.80 \end{aligned}$$

Recall: Out of the actual bad loan, how many did we correctly predict as a bad loan?

$$\begin{aligned} \text{Recall} &= \frac{TP}{TP + FN} \\ &= \frac{20}{20+20} = 0.50\% \end{aligned}$$

High Recall, Low Precision: This means that most of the positive examples are correctly recognized (low FN) but there are a lot of false positives.

Low Recall, High Precision: This shows that we miss a lot of positive examples (high FN) but those we predict as positive are indeed positive (low FP)

ตัวอย่าง 1

Bad Loan = 1

Good Loan = 0

Cost of FN > Cost of FP



Predict

	Actual	
	Bad Loan (1)	Good Loan (0)
Bad Loan (1)	✓ TP - 20	✗ FP - 5
Good Loan (0)	✗ FN - 20	✓ TN - 155

Precision: จากสินเชื่อที่คาดการณ์ว่าเป็นหนี้เสีย มันเป็นหนี้เสียจริงก็รายการ (เราจำแนกได้ถูกต้องรายการ)

$$\begin{aligned}
 Precision &= \frac{TP}{TP + FP} \\
 &= \frac{20}{20+5} = 0.80
 \end{aligned}$$

Recall: จากสินเชื่อที่เป็นหนี้เสียจริงทั้งหมด มีกี่รายที่เราคาดการณ์ได้ถูกต้องว่าเป็นหนี้เสีย? (จากสินเชื่อที่เป็นหนี้เสียจริงทั้งหมด มีกี่รายที่เราทำนายว่าเป็นหนี้เสีย)

$$\begin{aligned}
 Recall &= \frac{TP}{TP + FN} \\
 &= \frac{20}{20+20} = 0.50
 \end{aligned}$$

ตัวอย่าง 2

Bad Loan = 1

Good Loan = 0



Cost of FN > Cost of FP

Predict

Actual		
	Bad Loan (1)	Good Loan (0)
Bad Loan (1)	✓ TP - 36 👎	✗ FP - 30 👎
Good Loan (0)	✗ FN - 4 👍	✓ TN - 130 👍

Bad loan predicted as a good loan

Precision: จากสินเชื่อที่คาดการณ์ว่าเป็นหนี้เสีย มันเป็นหนี้เสียจริงก็รายการ (เราจำแนกได้ถูกต้องรายการ)

$$\begin{aligned}
 Precision &= \frac{TP}{TP + FP} \\
 &= \frac{36}{36+30} = 0.55
 \end{aligned}$$

Recall: จากสินเชื่อที่เป็นหนี้เสียจริงทั้งหมด มีกี่รายการที่เราคาดการณ์ได้ถูกต้องว่าเป็นหนี้เสีย? (จากสินเชื่อที่เป็นหนี้เสียจริงทั้งหมด มีกี่รายการที่เราทำนายว่าเป็นหนี้เสีย)

$$\begin{aligned}
 Recall &= \frac{TP}{TP + FN} \\
 &= \frac{36}{36+4} = 0.90
 \end{aligned}$$

ตัวอย่าง 1

Actual

Predict	Actual	
	Bad Loan (1)	Good Loan (0)
Bad Loan (1)	✓ TP - 20 👍	✗ FP - 5 👎
Good Loan (0)	✗ FN - 20 👎	✓ TN - 155 👍

Bad loan predicted as a good loan

ตัวอย่าง 2

Actual

Predict	Actual	
	Bad Loan (1)	Good Loan (0)
Bad Loan (1)	✓ TP - 36 👍	✗ FP - 30 👎
Good Loan (0)	✗ FN - 4 👎	✓ TN - 130 👍

Bad loan predicted as a good loan

Precision: จากสินเชื่อที่คาดการณ์ว่าเป็นหนี้เสีย มันเป็นหนี้เสียจริงกี่รายการ (เราจำแนกได้ถูกต้องรายการ)

$$Precision = \frac{TP}{TP + FP}$$

$$\frac{20}{20+5} = 0.80$$

ตัวอย่าง 1

$$\frac{20}{20+20} = 0.50$$

$$\frac{36}{36+30} = 0.55$$

ตัวอย่าง 2

$$\frac{36}{36+4} = 0.90$$

Recall: จากสินเชื่อที่เป็นหนี้เสียจริงทั้งหมด มีกี่รายที่เราคาดการณ์ได้ถูกต้องว่าเป็นหนี้เสีย?


$$Recall = \frac{TP}{TP + FN}$$

High Precision, Low Recall : This shows that we miss a lot of positive examples (high FN) but those we predict as positive are indeed positive (low FP)

Low Precision, High Recall : This means that most of the positive examples are correctly recognized (low FN) but there are a lot of false positives.

Confusion Matrix

A performance measurement for classification problem



Combining Precision and Recall – F1 Score

In the above three cases, we want to maximize either recall or precision at the expense of the other metric. For example, in the case of a good or bad loan classification, we would like to decrease FN to increase recall. However, in cases where we want to find an optimal blend of precision and recall, we can combine the two metrics using the F1 score.

$$F_1 \text{ score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

- F-Measure provides a single score that balances both the concerns of precision and recall in one number.
- A good F1 score means that you have low false positives and low false negatives, so you're correctly identifying real threats, and you are not disturbed by false alarms.
- An F1 score is considered perfect when it's 1, while the model is a total failure when it's 0.




ROC and AUC

Receiver-operating characteristic curve (ROC)


- The ROC curve is drawn by calculating the true positive rate (TPR) and false positive rate (FPR) at every possible threshold (in practice, at selected intervals), then graphing TPR over FPR.

Area under the curve (AUC)

- The area under the ROC curve (AUC) represents the probability that the model, if given a randomly chosen positive and negative example, will rank the positive higher than the negative.



ROC and AUC of completely random guesses



การคำนวณ ROC

ตัวอย่างข้อมูล: ลูกค้า 6 คน

ลูกค้า	Class	Predicted Prob. เป็น Bad
A	Bad (1)	0.90
B	Good (0)	0.80
C	Bad (1)	0.70
D	Good (0)	0.60
E	Good (0)	0.40
F	Bad (1)	0.30

ตัวอย่างคำนวณ Predicted Prob. จาก KNN

สมมติ $k = 5$

5 nearest neighbors มี class: ['Bad', 'Good', 'Bad', 'Bad', 'Good']

Predicted Probabilities:

- Bad = $3/5 = 0.6$
- Good = $2/5 = 0.4$

การคำนวณ ROC

- ทดลองกำหนด threshold = 0.70 → ลูกค้าที่มี Predicted Prob. ≥ 0.7 เราจะทำนายเป็น Bad

ลูกค้า	Predicted Prob. เป็น Bad	Predict	Actual	ผลลัพธ์
A	0.90	Bad	Bad	TP
B	0.80	Bad	Good	FP
C	0.70	Bad	Bad	TP
D	0.60	Good	Good	TN
E	0.40	Good	Good	TN
F	0.30	Good	Bad	FN

- คำนวณ TPR, FPR

$$\text{TPR (Recall)} = \text{TP} / (\text{TP} + \text{FN}) = 2 / (2 + 1) = 0.67$$

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN}) = 1 / (1 + 2) = 0.33$$

การคำนวณ ROC

- ลองไล่ threshold หลาย ๆ ค่า แล้วคำนวณ TPR, FPR

$$\text{TPR (Recall)} = \text{TP} / (\text{TP} + \text{FN})$$


$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$

Threshold	TP	FP	FN	TN	TPR (Recall)	FPR
≥ 0.90	1	0	2	3	$1/3 = 0.33$	$0/3 = 0.00$
≥ 0.80	1	1	2	2	0.33	$1/3 \approx 0.33$
≥ 0.70	2	1	1	2	0.67	0.33
≥ 0.60	2	2	1	1	0.67	0.67
≥ 0.40	2	3	1	0	0.67	1.00
≥ 0.30	3	3	0	0	1.00	1.00

การคำนวณ ROC

- Plot ROC Curve (จุดบนกราฟ)

FPR	TPR
0.00	0.33
0.33	0.33
0.33	0.67
0.67	0.67
1.00	0.67
1.00	1.00



หมายเหตุ ROC Curve ได้จากข้อมูลจำลอง 100 จุด

- เส้นโค้งสีน้ำเงินแสดงว่าโมเดลสามารถแยก class ได้ค่อนข้างดี
- AUC (พื้นที่ใต้กราฟ) $\approx 0.90 \rightarrow$ ถือว่าโมเดลมี performance ดีมาก