

ใบเสนอโครงการ (Project Proposal)

โปรเจกต์ที่ 1: OCR Transcript (สจล.)

วิชา 06026240 Intelligent System Development

กลุ่ม/Section

ความปลอดภัยของข้อมูลและการปฏิบัติตาม PDPA

⚠ Transcript (โดยเฉพาะภาพ Real) มีชื่อ-นามสกุล รหัสนักศึกษา ผลการเรียน และ GPA ซึ่งเป็น "ข้อมูลส่วนบุคคล" และผลการเรียนถือเป็นข้อมูลที่มีความอ่อนไหวสูงตาม พ.ร.บ.คุ้มครองข้อมูลส่วนบุคคล (PDPA) ทีมต้องวางมาตรการป้องกันก่อนเก็บ/ใช้ข้อมูล Real ทุกกรณี

ก่อนเก็บหรือใช้ Transcript ทุกฉบับ (ที่อาจารย์ให้หรือจัดหามาเอง) ทีมต้องได้เซ็นต์แบบฟอร์ม PDPA Consent ของรายวิชา เป็นลายลักษณ์อักษรก่อนเสมอ และนำข้อมูลไปใช้เพื่อวัตถุประสงค์การเรียนการสอนในรายวิชานี้เท่านั้น

Checklist มาตรการที่ทีมต้องปฏิบัติ (Tick หมายถึงทุกคนในทีม ได้ทำตามข้อปฏิบัติเหล่านี้อย่างเคร่งครัดทุกครั้ง ซึ่งเป็นข้อความส่วนหนึ่งในเอกสาร consent form ที่มีการแจ้งรายละเอียดตั้งแต่คาบสอง)

- ☐ ใช้ Transcript จริงเฉพาะฉบับที่ได้รับความยินยอมเป็นลายลักษณ์อักษรจากเจ้าของข้อมูลแล้วเท่านั้น
- ☐ เก็บข้อมูล ไฟล์ Transcript (Real หรือ Synthetic) รวมถึง ground truth ที่มาจากไฟล์ โดยมีการจำกัดสิทธิ์การเข้าถึง (access control) เฉพาะสมาชิกทีมและอาจารย์ผู้สอน
- ☐ เก็บข้อมูล ไฟล์ Transcript (Real หรือ Synthetic) รวมถึง ground truth ที่มาจากไฟล์ ในคอมพิวเตอร์ส่วนตัวที่มีการใส่รหัสผ่านที่ไม่ได้บอกใคร
- ☐ ไม่เก็บข้อมูล ไฟล์ Transcript (Real หรือ Synthetic) รวมถึง ground truth ที่มาจากไฟล์ ในคอมพิวเตอร์ที่มีบุคคลอื่นใช้
- ☐ ห้าม upload ไฟล์ Transcript (Real หรือ Synthetic) รวมถึง ground truth ที่มาจากไฟล์ ขึ้น public GitHub repository
- ☐ Anonymize/มาส์กข้อมูลอ่อนไหว (ชื่อ, รหัสนักศึกษา, เกรดรายวิชา) ก่อนนำไปใส่ใน slide/รายงาน/README ที่เผยแพร่ต่อบุคคลอื่น
- ☐ ไม่นำข้อมูลไปใช้เพื่อวัตถุประสงค์อื่นนอกเหนือจากการเรียนการสอนในรายวิชานี้

ระบุมাত্রการเพิ่มเติม (ถ้ามี) ที่ทีมจะดำเนินการเพื่อคุ้มครองข้อมูล:

ตัวอย่าง: จำกัดสิทธิ์เข้าถึงโฟลเดอร์ /dataset/, /gt/ ด้วยรหัสผ่านเฉพาะสมาชิกทีม 3 คน, ลบไฟล์ ทั้งหมดออกจากเครื่องพัฒนาและ private cloud storage ภายใน 7 วันหลังมีการประกาศเกรดรายวิชา, และใช้ Synthetic dataset ที่มีการเบลอ ข้อมูล ทั้งหมดในการนำเสนอในรายวิชา

1. ภาพรวมโปรเจกต์ (Overview)

อธิบายเป้าหมายของระบบโดยสรุป (2-4 บรรทัด):

ตัวอย่าง: ทีมจะพัฒนาระบบอ่าน Transcript สจล. อัตโนมัติ โดยใช้ OCR อะไรบ้าง อ่านข้อมูลรายวิชา หน่วยกิต เกรด และ GPA จากภาพ Transcript ทั้งแบบ synthetic, synthetic+noise และภาพจริง(ถ้ามี) แล้วบันทึกลงฐานข้อมูลเชิงสัมพันธ์เพื่อให้ค้นคืนและตรวจสอบย้อนหลังได้

2. ข้อมูล (Dataset) และ Ground Truth

★ เกี่ยวข้องกับเกณฑ์:

ข้อมูลของโปรเจกต์นี้ต้องประกอบด้วย 3 ประเภทครบถ้วน ระบุแหล่งที่มา จำนวน และไฟล์ ground truth ที่จะใช้ตรวจสอบของแต่ละประเภทให้ชัดเจน

ประเภทข้อมูล	แหล่งที่มา	จำนวน (ไฟล์/ภาพ)	Ground Truth มาจากไฟล์ใด (ระบุ format และตำแหน่งเก็บ)
Synthetic			
Synthetic & noise			
Real			

ตัวอย่าง: Synthetic 200 ภาพ (สร้างจากเทมเพลต Transcript สจล. + Faker ข้อมูลรายวิชา) | Synthetic & noise 200 ภาพ (เพิ่ม blur/skew/แสงไม่สม่ำเสมอ) | Real 1 ภาพ (Transcript ตัวอย่างของคนในกลุ่ม) — Ground truth เก็บเป็น ground_truth.json 1 ไฟล์ต่อภาพ ที่โฟลเดอร์ /dataset/gt/ ระบุฟิลด์ name, student_id, courses[], gpa

เช็คความครบถ้วนของข้อมูล

☐ Synthetic ☐ Synthetic & noise ☐ Real ☐ Ground truth ครบทุกภาพ รวม_____ ภาพ

☐ แบ่ง train_____ ภาพ/val_____ ภาพ/test_____ ภาพ เรียบร้อยแล้ว

3. Data Augmentation

ต้องจำลองสภาพเอกสารที่หลากหลาย เช่น สแกนเอียง แสงไม่สม่ำเสมอ กระดาษยับ เพื่อให้โมเดล OCR ทนทานต่อคุณภาพภาพที่แตกต่างกัน

รูปแบบ Augmentation	พารามิเตอร์ที่ใช้	เหตุผลที่เลือกใช้

ตัวอย่าง: Rotate $\pm 5^\circ$ (จำลองสแกนเอียง) | Gaussian noise $\sigma=0.02$ (จำลองสแกนคุณภาพต่ำ) | Brightness/Contrast $\pm 20\%$ (จำลองแสงถ่ายภาพไม่สม่ำเสมอ) | Perspective warp เล็กน้อย (จำลองถ่ายด้วยมือถือไม่ตรงมุม) — ใช้ Albumentations ReplayCompose เพื่อให้ transform สอดคล้องกับ ground truth เดิม

เป้าหมายจำนวนข้อมูลขั้นต่ำ (แยกตามระดับการศึกษา)

ตัวเลขด้านล่างเป็นตัวอย่าง นักศึกษากรอกจำนวนจริงที่ทีมทำในช่องขวา

ระดับการศึกษา	ภาพต้นฉบับ	Augmented ต่ภาพ (ตัวอย่าง)	จำนวนที่ทีมทำ
ป.ตรี	24 ภาพ	×3 เท่า (รวม ≥450)	
ป.บัณฑิต	24 ภาพ	×5 เท่า (รวม ≥750) + augmentation ขั้นสูง เช่น perspective warp/รอยพับ	

4. การ Labeling / Annotation

ฟิลด์ที่ label เพิ่มเติม จากที่อ.ให้ ในแต่ละภาพ Transcript:

ตัวอย่าง: ชื่อ-สกุลนักศึกษา, รหัสนักศึกษา, คณะ/สาขา, รายชื่อวิชา (รหัสวิชา/ชื่อวิชา/หน่วยกิต/เกรด), GPA
สะสม, ภาคการศึกษา, ตำแหน่งลายเซ็น/ตราประทับ (bounding box)

เครื่องมือและ Format ที่ใช้ labeling:

ตัวอย่าง: ใช้ Label Studio สำหรับ bounding box + text field, export เป็น COCO-JSON และแปลงเป็น
ground_truth.json ที่กำหนดเอง

5. แนวทางการอ่านภาพ (OCR)

ระบุโมเดล/บริการที่จะใช้ และเหตุผล:

ตัวอย่าง: ใช้ OpenCV Hough Transform หา keypoint 4 มุมของตาราง Transcript เพื่อทำ perspective
correction ก่อน OCR จากนั้นใช้ Tesseract เพื่อสกัดคำ

6. ออกแบบฐานข้อมูล (Database Design) (อันนี้อย่าเพิ่งใส่ เป็นส่วนหลัง midterm)

ระบุ Schema ของฐานข้อมูล อย่างน้อย 3 ตาราง พร้อมความสัมพันธ์ (relationship) ที่รองรับการ query ข้อมูลนักศึกษา/รายวิชา/เกรดได้จริง

ชื่อตาราง	ฟิลด์หลัก	Primary/Foreign Key	คำอธิบายความสัมพันธ์

ตัวอย่าง: students(student_id PK, name, faculty) — courses(course_id PK, course_name, credits) — transcripts(transcript_id PK, student_id FK→students, course_id FK→courses, grade, semester) — 1 student มีได้หลาย transcript record (1:N)

7. การประเมินความแม่นยำ (Evaluation Plan)

Metric ที่จะใช้วัดความแม่นยำ Field-level (เช่น accuracy, CER, WER, Exact match):

ตัวอย่าง: Field-level accuracy (เทียบ field ต่อ field กับ ground truth) และ Character Error Rate (CER) สำหรับข้อความอิสระ เช่น ชื่อวิชา

เกณฑ์การให้คะแนนตามความแม่นยำ (อ้างอิงเกณฑ์วิชา)

ช่วงความแม่นยำ ของวิธี CV-OCR	จำนวน ภาพ	หมายเหตุ
มากกว่า 91%	ได้คะแนน % จำนวน ภาพ	เป้าหมายที่ทีมควรตั้งไว้
80% – 90%	ได้คะแนน % จำนวน ภาพ	
น้อยกว่า 80%	ได้คะแนน % จำนวน ภาพ	ควรปรับปรุง pipeline เพิ่มเติม

8. แผนแอปพลิเคชันและเอกสารประกอบ (อันนี้อย่าเพิ่งใส่ เป็นส่วนหลัง midterm)

★ เกี่ยวข้องกับเกณฑ์: #5 แอปใช้งานได้จริง + เอกสาร — 10 คะแนน

รูปแบบแอปพลิเคชัน (เช่น Web app, CLI, Notebook demo) และแผนการ Deploy/Demo:

ตัวอย่าง: Web app (Streamlit) ให้อัปโหลดภาพ Transcript แล้วแสดงผลลัพธ์ OCR + บันทึกลงฐานข้อมูล พร้อม demo แบบ end-to-end

- ☐ Push code ขึ้น GitHub และแชร์กับ bhattarabhorn.wa@kmitl.ac.th (collaborate) ☐ มี README
- ☐ URL folder All Dataset ☐ มี Presentation/Slide หรือคู่มือการใช้งาน ☐ ส่งลิงก์ใน Discord กลุ่ม

สรุปเกณฑ์การให้คะแนนโปรเจกต์นี้ (อ้างอิง)

องค์ประกอบ	คะแนนเต็ม	สัมพันธ์กับหัวข้อในใบเสนอโครงการ
1. ออกแบบฐานข้อมูล / RAG	15	หัวข้อ 6
2. การอ่านภาพ: OCR / Keypoint, Skeleton	35	หัวข้อ 5
3. ความแม่นยำ / คุณภาพผลลัพธ์	40	หัวข้อ 7
4. LLM / Recommend	0	(ไม่มีในโปรเจกต์นี้)
5. แอปใช้งานได้จริง + เอกสาร	10	หัวข้อ 8