

ที่มาของเรื่อง

ในปัจจุบันธุรกิจอีคอมเมิร์ซมีการเติบโตอย่างรวดเร็ว ส่งผลให้เกิดข้อมูลจำนวนมากมหาศาลจากการทำธุรกรรมในแต่ละวัน ทั้งข้อมูลคำสั่งซื้อ ข้อมูลสินค้า ข้อมูลลูกค้า ข้อมูลผู้ขาย การชำระเงิน ตลอดจนความคิดเห็นและคะแนนรีวิวจากผู้ซื้อ ข้อมูลเหล่านี้มักถูกจัดเก็บกระจายอยู่ในหลายตารางและหลายระบบ ซึ่งถูกออกแบบมาเพื่อรองรับการทำธุรกรรม (Transactional System) เป็นหลัก จึงไม่เหมาะกับการนำมาวิเคราะห์เชิงลึก เนื่องจากการเชื่อมโยงข้อมูลจำนวนมากทำได้ช้าและส่งผลกระทบต่อประสิทธิภาพของระบบงานหลัก

ด้วยเหตุนี้ แนวคิดเรื่องคลังข้อมูล (Data Warehouse) จึงถูกนำมาใช้เพื่อรวบรวมข้อมูลจากหลายแหล่งมาจัดเก็บในรูปแบบที่เหมาะสมต่อการวิเคราะห์ อย่างไรก็ตาม การจัดตั้งคลังข้อมูลด้วยเครื่องมือช่วยภายในองค์กรจำเป็นต้องใช้เงินลงทุนสูงและต้องดูแลรักษาอย่างต่อเนื่อง ซึ่งเป็นข้อจำกัดสำคัญสำหรับผู้เริ่มต้นศึกษา

ผู้จัดทำจึงมีแนวคิดในการพัฒนาระบบคลังข้อมูลบนบริการคลาวด์ของ Amazon Web Services (AWS) โดยนำชุดข้อมูลจริงจากธุรกิจอีคอมเมิร์ซ Olist ประเทศบราซิล ซึ่งประกอบด้วยคำสั่งซื้อกว่า 100,000 รายการ ระหว่างปี ค.ศ. 2016 ถึง 2018 มาผ่านกระบวนการนำเข้า แปลง และจัดเก็บในรูปแบบ Star Schema เพื่อแสดงให้เห็นว่าการสร้างคลังข้อมูลสามารถทำได้โดยไม่ต้องลงทุนกับฮาร์ดแวร์จริง อีกทั้งยังสามารถปรับขยายทรัพยากรได้ตามความต้องการ และคิดค่าใช้จ่ายตามการใช้งานจริง ซึ่งเป็นการใช้ทรัพยากรอย่างคุ้มค่าและยั่งยืน

วัตถุประสงค์

- เพื่อศึกษาและออกแบบสถาปัตยกรรมคลังข้อมูล (Data Warehouse) บนระบบคลาวด์ โดยใช้บริการของ AWS
- เพื่อพัฒนาระบบการ ETL สำหรับนำเข้าและแปลงข้อมูลจากไฟล์ต้นทางให้อยู่ในรูปแบบ Star Schema ที่เหมาะสมต่อการวิเคราะห์
- เพื่อแสดงให้เห็นว่าการจัดเก็บและประมวลผลข้อมูลขนาดใหญ่สามารถดำเนินการได้โดยไม่ต้องมีฮาร์ดแวร์จริง
- เพื่อเปรียบเทียบประสิทธิภาพของการสืบค้นข้อมูลระหว่าง Amazon Athena ซึ่งสืบค้นข้อมูลจาก S3 โดยตรง กับ Amazon Redshift ซึ่งเป็นคลังข้อมูลโดยเฉพาะ
- เพื่อนำเสนอผลการวิเคราะห์ข้อมูลเชิงธุรกิจในรูปแบบ Dashboard ที่เข้าใจง่ายและนำไปใช้ประกอบการตัดสินใจได้

ประโยชน์ที่คาดว่าจะได้รับ

1. ได้ระบบคลังข้อมูลที่สามารถรองรับการวิเคราะห์ข้อมูลคำสั่งซื้อกว่า 100,000 รายการได้อย่างมีประสิทธิภาพ
2. เข้าใจหลักการออกแบบ Star Schema รวมถึงการแยก Fact Table และ Dimension Table ในการทำคลังข้อมูล
3. เข้าใจกระบวนการทำงานของ ETL Pipeline บนระบบคลาวด์ ตั้งแต่การนำเข้าข้อมูลจนถึงการนำไปแสดงผล
4. ได้ข้อมูลเชิงลึกทางธุรกิจ เช่น แนวโน้มยอดขายรายเดือน หมวดสินค้าที่ได้รับความนิยม และความสัมพันธ์ระหว่างระยะเวลาจัดส่งกับคะแนนรีวิวของลูกค้า
5. สามารถประเมินค่าใช้จ่ายและเลือกใช้บริการคลาวด์ได้อย่างเหมาะสมกับปริมาณงาน

ขอบเขตโครงการ

1. ใช้ชุดข้อมูล Brazilian E-Commerce Public Dataset by Olist ซึ่งเป็นข้อมูลเชิงพาณิชย์จริงที่ผ่านการปกปิดตัวตนแล้ว ประกอบด้วยตารางข้อมูลหลัก 8 ตาราง และตารางแปลชื่อหมวดหมู่สินค้าอีก 1 ตาราง รวมทั้งสิ้น 9 ไฟล์
2. จัดเก็บข้อมูลดิบบน Amazon S3 โดยแบ่งพื้นที่จัดเก็บออกเป็น Raw Zone และ Curated Zone
3. ทำความสะอาดข้อมูลด้วย AWS Glue DataBrew และแปลงข้อมูลด้วย AWS Glue ETL Job
4. ออกแบบคลังข้อมูลในรูปแบบ Star Schema ประกอบด้วย Fact Table 1 ตาราง และ Dimension Table 5 ตาราง ได้แก่ ลูกค้า สินค้า ผู้ขาย เวลา และการชำระเงิน
5. จัดเก็บคลังข้อมูลบน Amazon Redshift และสร้าง Dashboard สำหรับแสดงผลการวิเคราะห์
6. ตั้งค่าให้กระบวนการ ETL ทำงานโดยอัตโนมัติเมื่อมีไฟล์ข้อมูลใหม่เข้าสู่ระบบ ด้วย AWS Lambda และ Amazon EventBridge
7. ระบบนี้มุ่งเน้นการวิเคราะห์ข้อมูลย้อนหลัง (Batch Processing) ไม่ครอบคลุมการประมวลผลข้อมูลแบบทันที (Real-time Streaming)
8. ระบบพัฒนาและทดสอบภายใต้ข้อจำกัดของ AWS Academy Learner Lab ซึ่งจำกัดการใช้งานเฉพาะ Region us-east-1 และ us-west-2

บริการของ AWS ที่ใช้ในโครงการ

ตารางต่อไปนี้จะแสดงบริการของ AWS ที่นำมาใช้ในโครงการ พร้อมทั้งหน้าที่และข้อจำกัดภายใต้สภาพแวดล้อม AWS Academy Learner Lab

บริการของ AWS	หน้าที่ในระบบ	ข้อจำกัดใน Learner Lab
Amazon S3	จัดเก็บไฟล์ข้อมูลดิบ (Raw Zone) และข้อมูลที่ผ่านการแปลงแล้ว (Curated Zone) ทำหน้าที่เป็น Data Lake ของระบบ	ใช้งานได้ตามปกติ สามารถใช้ LabRole ได้
AWS Glue DataBrew	ทำความสะอาดข้อมูล เช่น ลบ ข้อมูลซ้ำ จัดการค่าว่าง และ ตรวจสอบคุณภาพข้อมูลเบื้องต้น	ใช้ LabRole ได้ ไม่มีข้อจำกัด พิเศษ
AWS Glue (ETL Job)	แปลงข้อมูลจากไฟล์ต้นทางทั้ง 9 ไฟล์ให้อยู่ในรูปแบบ Star Schema และคำนวณค่าเพิ่มเติม เช่น ระยะเวลาจัดส่ง	Worker type: G.1X หรือ Standard, จำนวน Worker สูงสุด 10, Concurrency สูงสุด 1
AWS Glue Data Catalog	จัดเก็บ Metadata และ Schema ของข้อมูลใน S3 เพื่อให้บริการอื่น เรียกใช้ได้	ใช้งานร่วมกับ Glue Crawler ได้ ตามปกติ
Amazon Redshift	ทำหน้าที่เป็นคลังข้อมูล (Data Warehouse) จัดเก็บ Fact และ Dimension Table สำหรับการ วิเคราะห์	รองรับเฉพาะ ra3.large และคลัสเตอร์ขนาดสูงสุด 2 Instance

Amazon Athena	ใช้ Query ข้อมูลใน S3 โดยตรงแบบ Serverless เพื่อเปรียบเทียบประสิทธิภาพกับ Redshift	ใช้ LabRole ได้ ไม่มีข้อจำกัดพิเศษ
AWS Lambda	ตรวจจับไฟล์ใหม่ที่เข้ามาใน S3 และสั่งให้ ETL Pipeline ทำงานโดยอัตโนมัติ	รันพร้อมกันได้สูงสุด 10 Execution Environment
Amazon EventBridge	ตั้งเวลาให้ Pipeline ทำงานตามรอบที่กำหนด และเชื่อมเหตุการณ์ระหว่างบริการ	ใช้ LabRole ได้
Amazon EC2	ติดตั้งเครื่องมือแสดงผล Dashboard จากภายนอก เช่น Metabase หรือ Apache Superset	รองรับ nano ถึง large เท่านั้น, รันพร้อมกันไม่เกิน 9 Instance และรวมไม่เกิน 32 vCPU
Amazon CloudWatch	ติดตามการทำงานของ ETL Job และเก็บ Log เพื่อตรวจสอบข้อผิดพลาด	ใช้งานได้ตามปกติ
AWS IAM (LabRole)	กำหนดสิทธิ์ให้บริการต่าง ๆ เข้าถึงทรัพยากรระหว่างกันได้	ไม่สามารถสร้าง User, Group หรือ Role ใหม่ได้ ต้องใช้ LabRole ที่เตรียมไว้